جامعة الحسن الأول
UNIVERSITÉ HASSAN 1er

ENCG
Settat

Rapport :

PRÉVISION DES MISES EN CHANTIER DE LOGEMENTS

ÉTUDE DE LA SAISONNALITÉ ET COMPARAISON DE MODÈLES DE PRÉVISION

Encadré par: Mr Abderrahim Larhlimi

Réalisé par :
Soha El Ghamri
Manal El Ghafiri
Groupe : FIN 2

Sommaire

Introduction.....3

Présentation de l'étude et des données.....4

Préparation et nettoyage des données.....5

Analyse exploratoire.....6

Décomposition et étude de la saisonnalité.....8

Construction des variables et découpage chronologique....10

Présentation des modèles de prévision.....11

Évaluation et comparaison des modèles.....12

Limites de l'étude et pistes d'amélioration.....13

Conclusion générale.....14

Introduction

Le secteur de la construction joue un rôle important dans l'activité économique. Les mises en chantier de logements, qui correspondent au début de la construction de nouveaux logements, constituent ainsi un indicateur suivi pour apprécier l'évolution du marché immobilier et du cycle économique.

Ce projet porte sur la série HOUST, diffusée par la Federal Reserve Bank of St. Louis à travers la plateforme FRED. Elle regroupe des observations mensuelles exprimées en milliers d'unités, en taux annualisé. L'étude cherche à déterminer si les mises en chantier suivent une saisonnalité prévisible et à comparer plusieurs méthodes capables de prévoir leur évolution.

La démarche repose sur l'importation et la préparation des données, l'analyse graphique et statistique de la série, la décomposition saisonnière, la création de variables explicatives, puis la construction et l'évaluation de trois modèles. Les performances sont comparées sur les 24 dernières observations à l'aide du RMSE et du MAPE.

1. Présentation de l'étude et des données

1.1. Problématique et objectifs

Problématique : les mises en chantier de logements suivent-elles une saisonnalité prévisible ?

L'objectif principal est de détecter une éventuelle saisonnalité exploitable et de produire des prévisions mensuelles. Il s'agit également de décrire les tendances et les cycles de la série, de comparer trois modèles de prévision et de discuter les limites des résultats.

1.2. Source et description des données

Les données proviennent de la série HOUST disponible sur FRED : https://fred.stlouisfed.org/series/HOUST. Le notebook exploite un fichier CSV contenant deux colonnes : observation_date, qui indique la date de l'observation, et HOUST, qui représente les mises en chantier.

Caractéristique	Description
Nombre d'observations	813 observations mensuelles
Période étudiée	Janvier 1959 à septembre 2026
Fréquence	Mensuelle
Unité	Milliers d'unités, en taux annualisé
Source	FRED – série HOUST

2. Préparation et nettoyage des données

La première étape consiste à importer les bibliothèques nécessaires à l'analyse : Pandas et NumPy pour la manipulation des données, Matplotlib et Seaborn pour les graphiques, Statsmodels pour les méthodes de séries temporelles et Scikit-learn pour la régression et les métriques.

Le fichier CSV est ensuite chargé dans Google Colab. Les dates sont converties au format datetime, les observations sont classées dans l'ordre chronologique et la date devient l'index de la série. Une fréquence mensuelle est explicitement définie à l'aide de asfreq('MS').

Les contrôles effectués indiquent qu'il n'existe aucune valeur manquante, aucune ligne dupliquée et aucune date dupliquée. La série comporte bien 813 mois consécutifs. Aucune observation n'a donc été supprimée lors du nettoyage.

Il faut toutefois signaler que les données HOUST peuvent être révisées après leur publication. Les valeurs récentes utilisées dans le projet correspondent à une version disponible au moment du téléchargement et peuvent donc évoluer ultérieurement

3. Analyse exploratoire

3.1. Statistiques descriptives

L'analyse descriptive permet de résumer le niveau général et la dispersion des mises en chantier. Les résultats principaux sont présentés ci-dessous.

Indicateur	Valeur
Nombre d'observations	813
Moyenne	1 430
Médiane	1 448
Écart-type	375
Minimum	478 – avril 2009
Maximum	2 494 – janvier 1972
Coefficient de variation	26 %

La moyenne et la médiane sont relativement proches. Cependant, l'écart-type et le coefficient de variation montrent que la série connaît des fluctuations importantes autour de son niveau moyen.

3.2. Évolution historique

Le graphique de la série complète met en évidence une alternance de périodes de hausse et de baisse. Plusieurs cycles apparaissent au cours de la période étudiée, avec des niveaux élevés au début des années 1970, au milieu des années 1980 et au début des années 2000. À l'inverse, des creux sont observés notamment en 1975, 1982, 1991 et surtout en 2009.

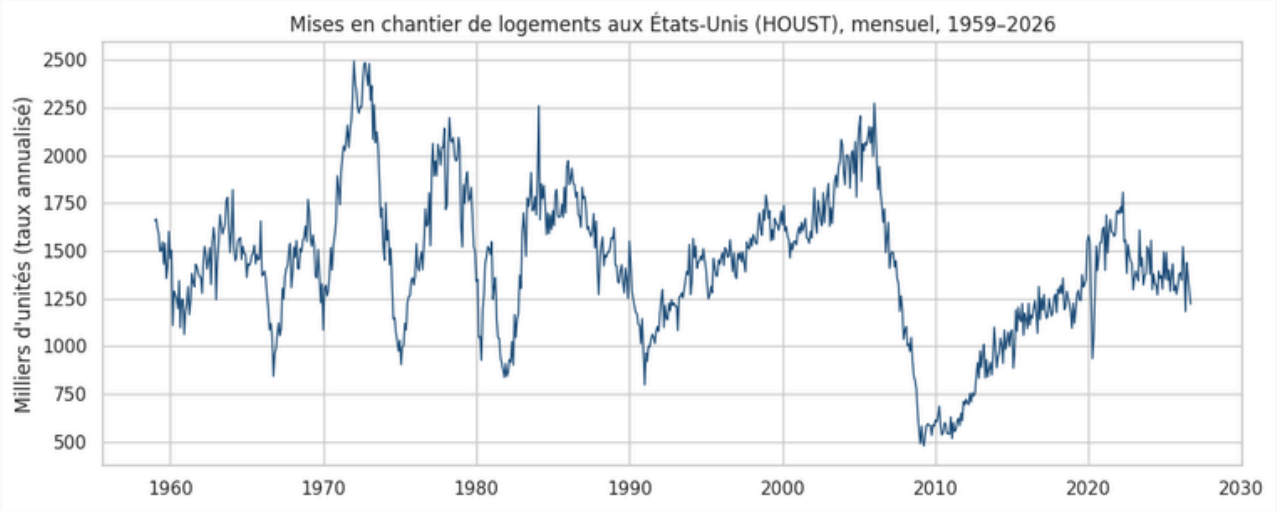


Figure 1 – Évolution mensuelle des mises en chantier aux États-Unis, 1959–2026.

Le zoom sur les années récentes, accompagné d'une moyenne mobile sur 12 mois, permet de distinguer les variations mensuelles des mouvements plus généraux. La moyenne mobile atténue les fluctuations de court terme et facilite la lecture de l'évolution globale.

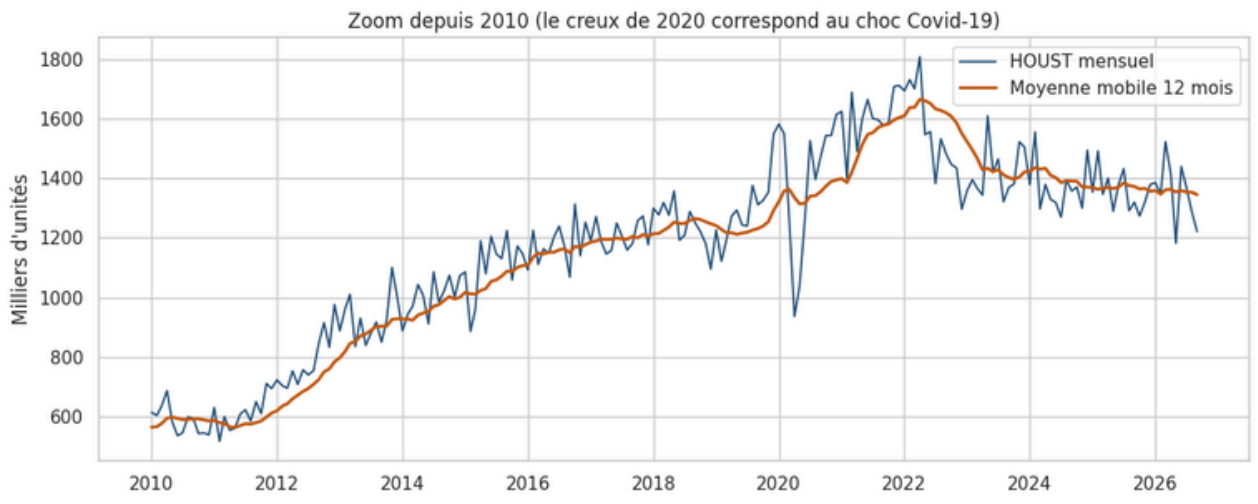


Figure 2 – Évolution depuis 2010 et moyenne mobile sur 12 mois.

Dans l'ensemble, la série est marquée par des cycles économiques et immobiliers. Elle ne suit pas une progression linéaire et régulière

4. Décomposition et étude de la saisonnalité

Pour étudier la saisonnalité, le notebook réalise une décomposition de la série avec une périodicité de 12 mois. Cette méthode distingue trois composantes : la tendance, qui représente l'évolution générale ; la saisonnalité, qui correspond aux variations périodiques ; et les résidus, qui regroupent les variations non expliquées par les deux premières composantes.

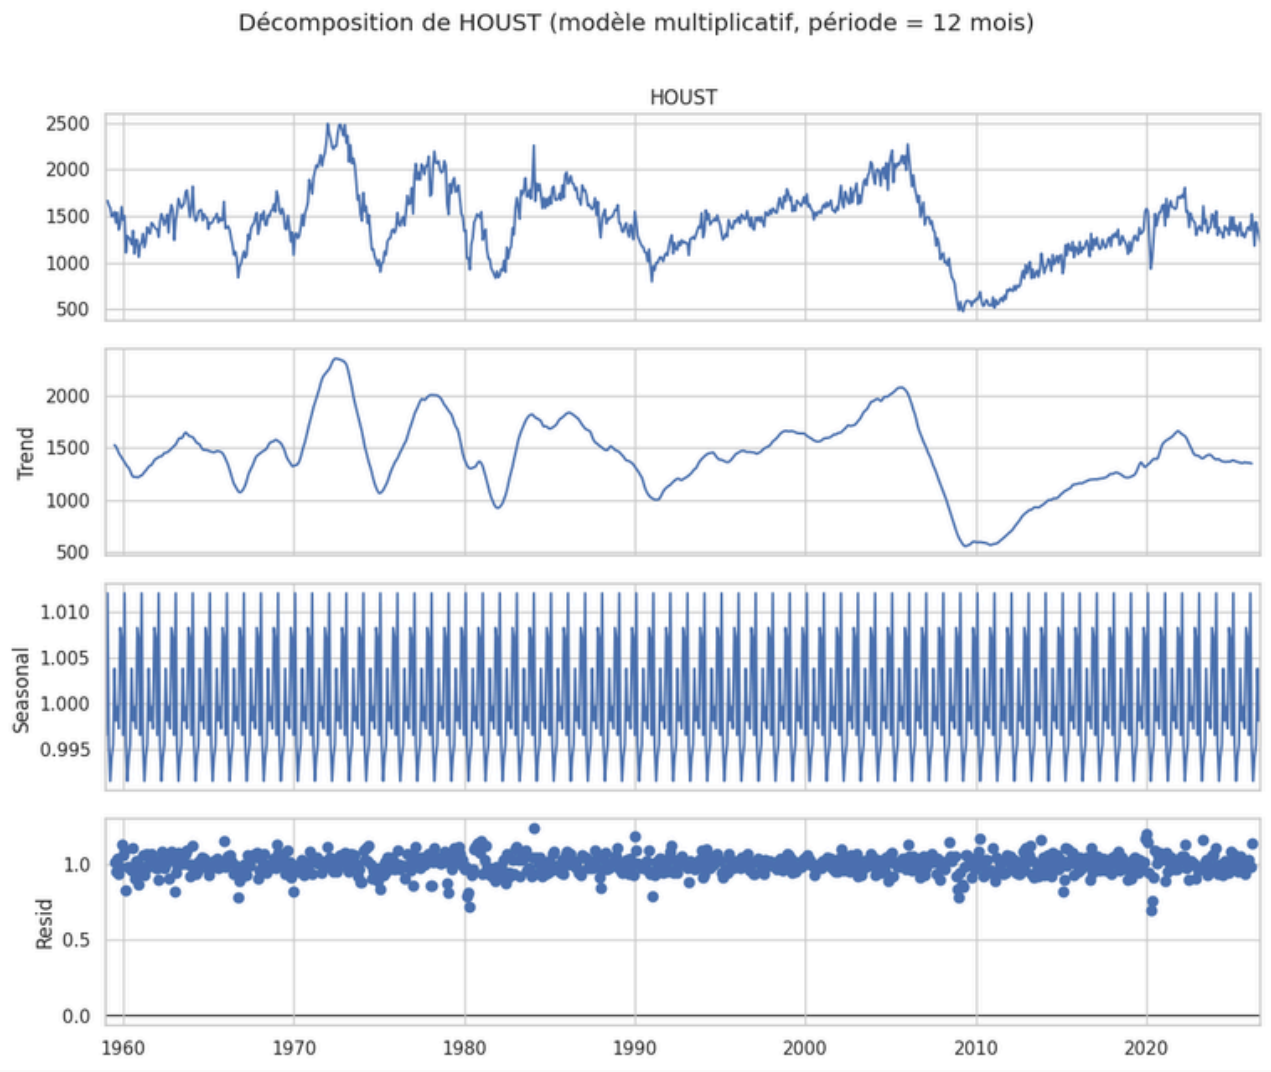


Figure 3 – Décomposition saisonnière de la série HOUST.

La décomposition fait apparaître une composante saisonnière de faible amplitude. Les coefficients saisonniers se situent entre 0,992 et 1,012. L'amplitude saisonnière totale est estimée à 2,05 %, alors que l'écart-type des résidus atteint 6,30 %. Les fluctuations résiduelles sont donc plus importantes que l'effet saisonnier estimé.

Deux tests statistiques complètent l'analyse : l'ANOVA et le test de Kruskal-Wallis. Ils servent à vérifier si les niveaux observés diffèrent significativement selon les mois.

Test	Statistique	P-value
ANOVA	0,688	0,751
Kruskal-Wallis	6,376	0,847

Les deux p-values sont supérieures au seuil de 5 %. Les tests ne permettent donc pas de rejeter l'hypothèse d'absence de différence significative entre les mois. L'analyse des autocorrélations ne met pas non plus en évidence de pics annuels significatifs aux retards de 12, 24 et 36 mois.

Point méthodologique important : la série HOUST utilisée est déjà corrigée des variations saisonnières. L'absence de saisonnalité détectable est donc cohérente avec la nature de cette série. Pour mesurer la saisonnalité réelle de l'activité de construction, il faudrait utiliser la série non corrigée HOUSTNSA.

5. Construction des variables et découpage chronologique

Avant la modélisation, le notebook construit des variables explicatives à partir de l'historique de la série. Les variables de mois permettent de représenter les éventuelles différences entre les douze mois de l'année. Les variables retardées (lag_1, lag_2 et lag_12) correspondent respectivement à la valeur du mois précédent, à celle de deux mois auparavant et à celle du même mois de l'année précédente.
Les données sont ensuite séparées en respectant l'ordre chronologique. Les 24 dernières observations sont réservées au test et les observations antérieures servent à l'entraînement.

Ensemble	Période	Observations
Entraînement	Janvier 1959 – septembre 2024	789
Test	Octobre 2024 – septembre 2026	24

Ce découpage évite d'utiliser des informations futures pour construire les modèles. Il reproduit ainsi une situation de prévision dans laquelle seules les données passées sont disponibles.

6. Présentation des modèles de prévision

6.1. Modèle de référence : moyenne par mois

Le premier modèle calcule, pour chaque mois, la moyenne des observations correspondantes dans l'ensemble d'entraînement. Cette moyenne est ensuite utilisée comme prévision pour le même mois dans la période de test. Les moyennes mensuelles sont comprises entre environ 1 420 et 1 452, ce qui confirme que le profil mensuel est presque plat.

6.2. Lissage exponentiel de Holt-Winters

Le deuxième modèle est la méthode de Holt-Winters. Elle permet de prendre en compte le niveau de la série, sa tendance et une éventuelle composante saisonnière. Quatre configurations sont comparées : sans tendance avec saisonnalité additive, sans tendance avec saisonnalité multiplicative, tendance amortie avec saisonnalité additive et tendance amortie avec saisonnalité multiplicative.

Le choix de la configuration repose sur le critère AIC : parmi les configurations testées, celle qui présente l'AIC le plus faible est retenue. Il s'agit de la configuration avec tendance amortie et saisonnalité multiplicative. Son paramètre saisonnier gamma est égal à 0,000, ce qui indique que la composante saisonnière n'est pas actualisée par le modèle.

6.3. Régression linéaire avec variables mensuelles et retards

Le troisième modèle est une régression linéaire qui utilise les variables de mois ainsi que les retards lag_1, lag_2 et lag_12. Le coefficient de détermination sur l'entraînement est de 0,921. Les coefficients les plus importants sont ceux de lag_1 et lag_2, tandis que lag_12 et les variables mensuelles apportent peu d'information.

Les prévisions sont calculées de manière récursive : à partir du deuxième mois de test, les prévisions précédentes sont réutilisées comme valeurs retardées. Les valeurs réelles de la période de test ne sont donc pas utilisées dans le calcul des prévisions futures. Cette méthode peut toutefois entraîner une accumulation des erreurs au fil de l'horizon de prévision.

7. Évaluation et comparaison des modèles

Les trois modèles sont évalués sur les mêmes 24 observations de test. Deux indicateurs sont utilisés. Le RMSE mesure l'importance des erreurs en pénalisant davantage les erreurs élevées. Le MAPE exprime l'erreur absolue moyenne en pourcentage de la valeur réelle. Pour ces deux indicateurs, une valeur plus faible indique une meilleure précision.

Modèle	RMSE	MAPE
Holt-Winters	81,03	4,81 %
Régression (mois + retards)	88,29	5,29 %
Moyenne par mois	109,52	6,95 %

Le modèle Holt-Winters obtient les erreurs les plus faibles : un RMSE de 81,03 et un MAPE de 4,81 %. Il constitue donc le modèle le plus performant parmi les trois méthodes comparées sur la période de test.

La régression arrive en deuxième position, avec un MAPE de 5,29 %. Elle tire principalement son pouvoir explicatif des valeurs récentes de la série. Le modèle de moyenne par mois est le moins précis, car il produit des prévisions presque constantes et ne s'adapte pas suffisamment aux changements de niveau.

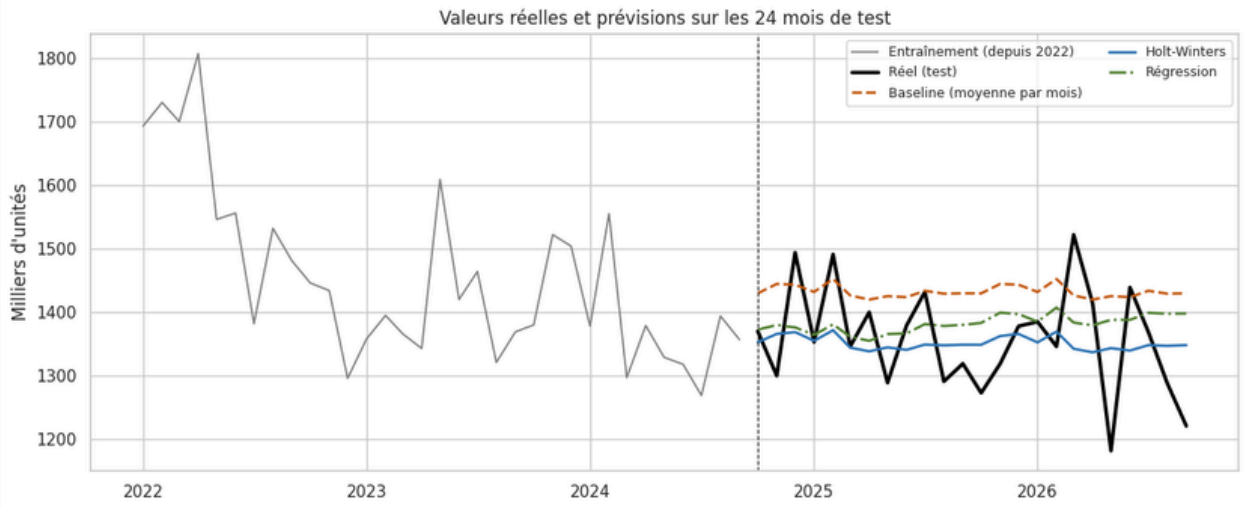


Figure 4 – Comparaison des valeurs réelles et des prévisions sur les 24 mois de test

Le graphique montre que les valeurs réelles fluctuent davantage que les prévisions des trois modèles, qui restent relativement stables. Les modèles estiment donc surtout le niveau moyen de la série, sans reproduire toutes les oscillations mensuelles. Holt-Winters réalise néanmoins le meilleur compromis parmi les modèles testés.

L'erreur moyenne est également informative : la moyenne par mois surestime les valeurs réelles d'environ 74 unités, tandis que Holt-Winters présente une erreur moyenne d'environ −7 unités. La régression surestime en moyenne d'environ 24 unités.

8. Limites de l’étude et pistes d’amélioration

Les trois modèles sont évalués sur les mêmes 24 observations de test. Deux indicateurs sont utilisés. Le RMSE mesure l’importance des erreurs en pénalisant davantage les erreurs élevées. Le MAPE exprime l’erreur absolue moyenne en pourcentage de la valeur réelle. Pour ces deuLes résultats doivent être interprétés en tenant compte de plusieurs limites.

- La série HOUST est déjà corrigée des variations saisonnières. Elle ne permet donc pas d’identifier directement la saisonnalité naturelle des mises en chantier.

- Les données peuvent être révisées après leur publication. Les valeurs récentes et les erreurs calculées sur la période de test peuvent donc changer.

- L’évaluation repose sur un seul découpage chronologique et seulement 24 observations de test. Une validation sur plusieurs périodes permettrait de vérifier la stabilité des résultats.

- Les ruptures structurelles, notamment la crise immobilière de 2008 et la période de la Covid-19, peuvent rendre les relations historiques moins stables.

- Les modèles n’intègrent pas de facteurs économiques externes tels que les taux hypothécaires, les permis de construire ou le coût des matériaux.

Pour approfondir l’étude, il serait pertinent d’utiliser HOUSTNSA afin d’étudier la saisonnalité non corrigée, de mettre en place une validation glissante, d’ajouter des variables économiques explicatives et de tester d’autres méthodes comme SARIMA ou des modèles de machine learning fondés sur les retards.
x indicateurs, une valeur plus faible indique une meilleure précision.

Conclusion

Cette étude avait pour objectif de déterminer si les mises en chantier de logements aux États-Unis suivent une saisonnalité prévisible et de comparer plusieurs méthodes de prévision. L'analyse de la série HOUST ne met pas en évidence de saisonnalité mensuelle significative. Les tests statistiques, la décomposition et les moyennes mensuelles convergent vers ce constat. Ce résultat doit toutefois être replacé dans son contexte : HOUST est une série déjà corrigée des variations saisonnières.

La comparaison des trois modèles montre que Holt-Winters obtient les meilleures performances sur les 24 derniers mois, avec un RMSE de 81,03 et un MAPE de 4,81 %. Il est suivi par la régression linéaire, puis par la moyenne mensuelle, qui présente les erreurs les plus élevées.

En définitive, les résultats suggèrent que la prévision de cette série dépend davantage de l'évolution récente de son niveau et de ses cycles que d'un effet saisonnier mensuel. Les conclusions restent néanmoins limitées par les révisions possibles des données, la durée de la période de test et l'absence de variables économiques externes.